实验报告

1. 实验目的

本实验使用 CUB-200-2011 数据集完成 200 类鸟类图像分类。相较于初始的单卷积层模型，本实验采用包含四个卷积层的卷积神经网络，并使用分层十折交叉验证评估模型的泛化能力。同时，通过数据增强、Batch Normalization、Dropout、权重衰减和 Label Smoothing 缓解过拟合。

2. 实验设置

- 数据集：CUB-200-2011，共 11,788 张图像、200 个类别。
- 交叉验证：StratifiedKFold，10 折，随机种子 42。
- 每折数据量：通常为 10,609 张训练图像和 1,179 张验证图像；第 9、10 折为 10,610/1,178。
- 输入图像：统一缩放为 224×224，三通道 RGB。
- 训练增强：随机水平翻转、归一化。
- 优化器：AdamW，初始学习率 1e-3，weight decay 1e-4。
- 损失函数：带 label_smoothing=0.1 的交叉熵损失。
- 最大训练轮数初始设置为10；学习率调度器为 ReduceLROnPlateau。

3. 模型架构设计

模型输入尺寸为 3×224×224。卷积层使用 3×3 卷积核、步长 1、padding 1。每个卷积块后使用 2×2 池化，最后使用自适应平均池化，使分类器不依赖于固定的空间尺寸。

层	结构	输入尺寸	输出尺寸	可训练参数
Input	RGB 图像	3×224×224	3×224×224	0
Conv1	Conv2d(3, 32, 3×3, padding=1)	3×224×224	32×224×224	864
BN1	BatchNorm2d(32)	32×224×224	32×224×224	64
ReLU1 + Pool1	ReLU；MaxPool2d(2)	32×224×224	32×112×112	0
Conv2	Conv2d(32, 64, 3×3, padding=1)	32×112×112	64×112×112	18,432
BN2	BatchNorm2d(64)	64×112×112	64×112×112	128
ReLU2 + Pool2	ReLU；MaxPool2d(2)	64×112×112	64×56×56	0

层	结构	输入尺寸	输出尺寸	可训练参数
Conv3	Conv2d(64, 128, 3×3, padding=1)	64×56×56	128×56×56	73,728
BN3	BatchNorm2d(128)	128×56×56	128×56×56	256
ReLU3 + Pool3	ReLU；MaxPool2d(2)	128×56×56	128×28×28	0
Conv4	Conv2d(128, 256, 3×3, padding=1)	128×28×28	256×28×28	294,912
BN4	BatchNorm2d(256)	256×28×28	256×28×28	512
ReLU4	ReLU	256×28×28	256×28×28	0
AdaptiveAvgPool	AdaptiveAvgPool2d(1,1)	256×28×28	256×1×1	0
Flatten	展平	256×1×1	256	0
Dropout	Dropout(0.4)	256	256	0
Classifier	Linear(256, 200)	256	200	51,400

参数量计算如下：

- 卷积层：864 + 18,432 + 73,728 + 294,912 = 387,936。
- BatchNorm 层：64 + 128 + 256 + 512 = 960。
- 全连接层：256×200 + 200 = 51,400。
- 总参数量：387,936 + 960 + 51,400 = 440,296。

4. 10epoch十折实验结果

下表给出每一折第 10 个 epoch 的训练和验证结果，由于本次运行每一折均在第 10 个 epoch 达到该折的最高验证准确率，因此第 10 个 epoch 同时也是各折的最佳结果。

Fold	Train loss	Train acc	Val loss	Val acc
1	4.4524	0.0953 (9.53%)	4.5614	0.0831 (8.31%)
2	4.5117	0.0831 (8.31%)	4.5833	0.0848 (8.48%)
3	4.4827	0.0873 (8.73%)	4.5649	0.0857 (8.57%)
4	4.4780	0.0865 (8.65%)	4.5739	0.0857 (8.57%)
5	4.4856	0.0878 (8.78%)	4.5183	0.0865 (8.65%)
6	4.4521	0.0894 (8.94%)	4.5267	0.0908 (9.08%)

Fold	Train loss	Train acc	Val loss	Val acc
7	4.4852	0.0871 (8.71%)	4.5470	0.0967 (9.67%)
8	4.4265	0.1010 (10.10%)	4.5185	0.0823 (8.23%)
9	4.4803	0.0893 (8.93%)	4.5198	0.0951 (9.51%)
10	4.4424	0.0945 (9.45%)	4.5272	0.0806 (8.06%)

各折最佳验证准确率范围为 8.06%～9.67%，说明不同划分下模型表现相对稳定，但整体准确率仍然偏低。从每一折的完整日志可以观察到：训练 loss 与验证 loss 均逐步下降，说明模型确实学习到了有效特征。

5.增大epoch至50

由于每一折均在第 10 个 epoch 达到该折的最高验证准确率，表明训练 epoch 不足，将最大训练轮数由 10 提高至 50 后，均触发 Early stopping，最佳验证准确率及对应训练结果如下表所示。

Fold	最佳验证准确率所在 Epoch	Train loss	Train acc	Val loss	Val acc	Early stopping Epoch
1	25	4.1343	0.1517 (15.17%)	4.3369	0.1374 (13.74%)	28
2	34	3.6218	0.2657 (26.57%)	3.8052	0.2494 (24.94%)	37
3	16	4.2404	0.1303 (13.03%)	4.4424	0.1238 (12.38%)	19
4	38	3.4369	0.3125 (31.25%)	3.7322	0.2680 (26.80%)	41
5	30	3.7918	0.2437 (24.37%)	3.8834	0.1855 (18.55%)	33
6	35	3.5216	0.2928 (29.28%)	3.8643	0.2138 (21.38%)	38
7	22	4.0519	0.1739 (17.39%)	4.1222	0.1528 (15.28%)	25
8	36	3.1198	0.3289 (32.89%)	3.7822	0.2364 (23.64%)	39

Fold	最佳验证准确率所在 Epoch	Train loss	Train acc	Val loss	Val acc	Early stopping Epoch
9	29	3.1899	0.2488（24.88%）	3.9523	0.1787（17.87%）	32
10	32	3.3467	0.2738（27.38%）	3.8457	0.2042（20.42%）	35

十折最佳验证准确率范围为 12.38%～26.80%。与 10 epoch 十折实验的最佳验证准确率均值 8.71% ± 0.51% 相比，说明增加训练轮数对模型性能有明显改善。但另一方面，即使增大至 50 epoch，最佳验证准确率仍整体偏低，暂未表现出明显过拟合，更多表现为欠拟合。

6. 过拟合分析

初始模型出现严重过拟合，baseline 训练结果如下：

Epoch	Train Loss	Train Acc	Val Loss	Val Acc
1/10	5.3691	0.0482（4.82%）	4.6435	0.0645（6.45%）
2/10	3.2910	0.2916（29.16%）	4.7231	0.0848（8.48%）
3/10	1.3916	0.7029（70.29%）	5.6962	0.0780（7.80%）
4/10	0.3849	0.9300（93.00%）	6.7137	0.0738（7.38%）
5/10	0.1458	0.9763（97.63%）	7.2547	0.0628（6.28%）
6/10	0.1131	0.9811（98.11%）	7.6480	0.0636（6.36%）
7/10	0.0931	0.9849（98.49%）	7.9066	0.0704（7.04%）
8/10	0.0673	0.9879（98.79%）	7.6159	0.0746（7.46%）
9/10	0.0834	0.9835（98.35%）	7.8968	0.0687（6.87%）
10/10	0.0628	0.9879（98.79%）	8.3759	0.0653（6.53%）

第 1 轮训练准确率为 4.82%，第 5 轮升到 97.63%，第 10 轮达到 98.79%。验证准确率却始终很低，这说明模型很快记住了训练图像，却没有学到能泛化到新图像的特征。主要原因是初始模型虽然只有一个卷积层，共计大约有 251 万个参数，其中绝大部分集中在全连接层。与此同时，训练方案没有 Dropout、权重衰减或数据增强，CUB-200 又是有 200 类的细粒度分类任务，只靠一层卷积很难提取足够有区分度的鸟类局部特征。

当前模型没有出现典型的过拟合，主要原因是代码中已采取以下抑制过拟合措施：

- BatchNorm：稳定不同 batch 的特征分布，加快训练收敛。

- Dropout(0.4)：降低分类器对单一特征的依赖。
- AdamW weight decay：约束模型参数规模。
- 随机水平翻转：增加训练样本的外观变化。
- Label Smoothing：降低模型过度自信。
- ReduceLROnPlateau 和 Early Stopping：验证指标不再改善时降低学习率或停止训练。

7. 结果讨论

模型平均准确率较低，CUB-200-2011 是细粒度分类数据集，仅使用从零开始训练的小型 CNN 难以获得足够强的判别特征。后续可以考虑：

1. 使用预训练的模型，对最后分类层进行微调。
2. 修改模型结构，增加可训练参数。
3. 使用更适合细粒度识别的随机裁剪、颜色扰动和目标区域裁剪。